

BLM22438 - Derin Öğrenmeye Giriş Ödev-2

HAZIRLAYAN : MUHAMMED EMİN KORKUNÇ - 2021221054

RAPOR : ISIC2018 Cilt Lezyonları Segmentasyonu – U-Net Raporu

1. Problem Tanımı ve Amaç

Bu projede, MedSegBench platformu tarafından sunulan ISIC2018 alt veri seti kullanılarak cilt lezyonlarının semantik segmentasyonu hedeflenmiştir.

Cilt kanserlerinin erken teşhisi açısından büyük öneme sahip bu segmentasyon problemini çözmek amacıyla U-Net mimarisi tercih edilmiştir.

Amaç, girdi olarak verilen deri görüntülerinden lezyon bölgesini başarılı bir şekilde segmentlemek ve modelin başarımını uygun metriklerle değerlendirmektir.

2. Kullanılan Model ve Mimari


Segmentasyon problemi için U-Net mimarisi kullanılmıştır. U-Net; encoder (downsampling) ve decoder (upsampling) bloklarından oluşur.

Proje kapsamında kullanılan U-Net modeli, medikal görüntü segmentasyonu için yaygın olarak tercih edilen ve encoder-decoder mimarisine sahip bir yapıdır. Model, girişte 3 kanallı (RGB) deri görüntülerini alır ve çıktı olarak 1 kanallı bir segmentasyon maskesi üretir. Encoder kısmında, sırasıyla 64 ve 128 filtrelili iki adet "DoubleConv" bloğu kullanılmıştır. Her blok içinde, ardışık iki konvolüsyon katmanı ve ReLU aktivasyon fonksiyonları yer almaktadır. Bu blokları takip eden MaxPool katmanları sayesinde, uzamsal boyutlar yarıya indirilerek daha derin özellik haritaları elde edilmiştir.

Modelin ortasında yer alan "bottleneck" kısmında, 256 filtre içeren bir DoubleConv bloğu bulunmaktadır. Decoder aşamasında ise, ConvTranspose2D katmanları ile uzamsal boyutlar artırılmış; ardından encoder katmanlarından gelen karşılık gelen özellik haritaları ile concatenate edilerek skip-connection uygulanmıştır. Böylece hem düşük seviye detaylar hem de yüksek seviye semantik bilgiler bir arada öğrenilmiştir. Decoder kısmında, sırasıyla 128 ve 64 filtrelili DoubleConv blokları bulunmaktadır. Modelin sonunda yer alan 1x1 konvolüsyon katmanı ile çıktı 1 kanallı hale getirilmiş ve sigmoid aktivasyon fonksiyonu ile her pikselin maske olma olasılığı 0-1 aralığında elde edilmiştir.

Bu yapıyla U-Net modeli, hem lezyonların detaylarını hem de genel konum bilgisini koruyarak başarılı bir segmentasyon gerçekleştirmektedir.

Aşağıda U-Net mimarisinin şematik gösterimi yer almalıdır:



[Şekil 1: U-Net Mimari Diyagramı]

3. Eğitim Süreci ve TensorBoard Görselleri


Model, augmentasyon uygulanmış veri ile 150 epoch'a kadar eğitilmiş; ancak validation kaybı 30 epoch boyunca iyileşmediği için 64. epoch'ta erken durdurma mekanizması ile eğitim sonlandırılmıştır.

Eğitim sürecinde kullanılan optimizasyon, kayıp fonksiyonu ve doğruluk değişimleri TensorBoard üzerinde izlenmiştir.


Aşağıdaki şekilde, modelin eğitim süresince Accuracy/Train (eğitim doğruluğu) ve Accuracy/Val (validasyon doğruluğu) değerlerinin epoch bazında değişimi görülmektedir:

- Accuracy/Train eğrisi yaklaşık 0.85 civarında başlayıp istikrarlı bir şekilde artarak 64. epoch sonunda 0.8939 değerine ulaşmıştır. Bu durum, modelin eğitim verileri üzerinde öğrenmeye devam ettiğini göstermektedir.
- Accuracy/Val eğrisi ise eğitim boyunca dalgalı bir seyir izlese de genel olarak %87 doğruluğa kadar yükselmiş ve son adımda 0.8754 değeri elde edilmiştir. Bu, modelin doğruluğunun sadece eğitim verisi üzerinde değil, görülmeyen doğrulama verileri üzerinde de yüksek olduğunu gösterir.
- Validasyon doğruluğundaki dalgalanmalar, medikal görüntülerdeki çeşitlilik ve veri setindeki sınıf dengesizliklerinden kaynaklanıyor olabilir.
- Eğitim ve validasyon doğruluğunun birbirine yakın ve yüksek seviyelerde olması, overfitting olmadığını, modelin genelleme kapasitesinin güçlü olduğunu işaret eder.

Aşağıdaki ekran görüntüsü TensorBoard çıktısına örnektir:



[Şekil 2: TensorBoard'da Accuracy Eğrileri]



[Şekil 3: TensorBoard Görsel Logları (Input-Predicted-GroundTruth)]

1. Sol: Orijinal giriş (input) cilt lezyon görüntüsü
2. Orta: Model tarafından tahmin edilen (predicted) segmentasyon maskesi
3. Sağ: Gerçek (ground truth) segmentasyon maskesi

Modelin tahmin ettiđi maske genel olarak hedef bölgeye oldukça yakın konumlanmıştır. Özellikle ikinci ve üçüncü satırlarda görüldüğü gibi, model sınırlarda küçük sapmalar dışında bölütleme görevini başarıyla gerçekleştirmiştir. Ancak birinci örnekte modelin bazı hatalı bölgeleri maskelediğı görülmektedir. Bu durum, cilt dokusundaki renk ve doku benzerliklerinden veya modelin henüz o tür varyasyonları yeterince genelleyememesinden kaynaklanıyor olabilir.

Bu görselleştirme, modelin doğrulama sırasında öğrenme sürecinde neleri iyi yaptığı ve hangi örneklerde hata yapabileceğı hakkında niteliksel bilgi sunmaktadır. Bu tarz görseller, modelin sadece sayısal metriklerle değıl, aynı zamanda görsel performansı ile de değerlendirilmesini sağlar.

4. Kullanılan Hiperparametreler

Modelin eğitimi sürecinde kullanılan tüm hiperparametreler aşağıda listelenmiştir:

Parametre	Değer
Model	U-Net
Giriş Görüntü Boyutu	256 × 256
Giriş Kanalı	3 (RGB)
Çıkış Kanalı	1 (Binary Mask)
Epoch Sayısı (maksimum)	150
Erken Durdurma	Val loss 30 epoch boyunca iyileşmezse
Batch Size	8
Öğrenme Oranı (Learning Rate)	1e-4

Optimizasyon Algoritması Adam

Kayıp Fonksiyonu BCE Loss + Dice Loss

Aktivasyon Fonksiyonu ReLU (Ara katmanlarda) / Sigmoid (çıkıtı)

Veri Artırma (Augmentation) Horizontal Flip, Random Rotation (15°), ColorJitter (brightness=0.2, contrast=0.2)

Segmentasyon Eşik Değeri 0.5

Normalizasyon Maskeleri 0–1 aralığına normalize etme

Eğitim / Doğrulama / Test Ayrımı MedSegBench varsayılan bölmeleri

5. Test Sonuçları ve Örnek Çıktılar

Modelin test veri seti üzerinde segmentasyon başarımları aşağıdaki gibidir:

- **Accuracy** (0.86) değeri yüksek olup modelin genel olarak iyi tahmin yaptığına işaret etmektedir.
- **Precision** değerinin **recall**'dan yüksek olması, modelin yanlış pozitif üretme eğilimini kontrol edebildiğini gösterir.
- **F1 Score** (0.74), modelin hem doğru pozitif tahminlerde hem de genel denge açısından başarılı olduğunu ortaya koyar.
- **IoU** değeri segmentasyon problemlerinde kritik bir metriktir ve 0.59 değeri makul bir performansa işaret etmektedir.


Bu metrikler, modelin segmentasyon görevinde oldukça yeterli bir performans sergilediğini göstermektedir. Özellikle erken durdurma mekanizması sayesinde modelin overfitting eğilimi önlenmiştir.

Metrik	Değer
Test Accuracy	0.8625
Test Precision	0.7695
Test Recall	0.7262
Test F1 Score	0.7472
Test IoU	0.5964

Aşağıdaki görsel modelin test sonrası segmentasyon örneklerini göstermektedir:

Aşağıda, test verisinden alınmış üç farklı örneğe ait giriş (Input Image), model tarafından tahmin edilen maske (Predicted Mask) ve gerçek hedef maske (Ground Truth Mask) görselleri gösterilmektedir. Bu görseller modelin segmentasyon başarısını görsel olarak incelemek amacıyla rapora dahil edilmiştir.

İlk satırdaki örnekte model giriş görüntüsünü hatalı yorumlamış ve segmentasyon maskesinde belirgin gürültü (yanlış pozitif alanlar) gözlemlenmiştir. Ancak ikinci ve üçüncü örneklerde modelin tahmini ile gerçek maske oldukça uyumludur. Bu durum, modelin çoğu durumda başarılı ancak karmaşık doku veya düşük kontrastlı alanlarda zorlanabildiğini göstermektedir.



[Şekil 4: Test Verisinde Segmentasyon Örnekleri]

6. MedSegBench Makalesi ile Karşılaştırma

MedSegBench makalesine göre ISIC2018MSBench veri setiyle yapılan deneylerde, EfficientNet encoder'lı U-Net modeli en iyi performansı göstermiştir. Bu model ile aşağıdaki ortalama metrikler elde edilmiştir:

Metrik	EfficientNet (MedSegBench)	Bu Proje Sonucu
Precision	0.857	0.7695
Recall	0.923	0.7262
F1-Score	0.868	0.7472
IoU	0.790	0.5964

Karşılaştırmalı Değerlendirme:

- **MedSegBench çalışmasında U-Net + EfficientNet kullanımı ile yüksek başarı** elde edilmiştir. Bu yapı, transfer learning ve güçlü encoder mimarisi sayesinde hassasiyet

(Recall) ve doğruluk (Precision) arasında denge kurmuştur.

- Bu projede ise sıfırdan eğitilmiş sade bir U-Net kullanılmış ve veri artırma ile desteklenmiştir. Ancak encoder tarafında EfficientNet gibi gelişmiş bir yapı tercih edilmediği için metrikler biraz daha düşük kalmıştır.
- Özellikle IoU ve F1-score açısından fark gözle görülür düzeydedir. Bu durum, modelin segmentasyon maskesini tam anlamıyla örtüştürmekte zorlandığını göstermektedir.
- Yine de bu sonuçlar, temel bir U-Net mimarisiyle ve augmentasyon teknikleriyle, güçlü bir temel segmentasyon modeli oluşturulduğunu göstermektedir.

Not: Bu fark, yapılan optimizasyon teknikleri, encoder seçimi, pretraining kullanımı, epoch sayısı ve augmentation çeşitliliği gibi faktörlere dayanmaktadır. Eğer bu çalışmada EfficientNet tabanlı encoder'lar, daha yüksek çözünürlük (512×512) ve uzun süreli eğitimler kullanılsaydı, MedSegBench değerlerine daha da yaklaşılabilirdi.

7. Deneysel Gözlemler ve Geliştirme Önerileri

Model, segmentasyon görevinde özellikle küçük ve ayrık lezyonları ayırt etmekte zaman zaman zorlanmıştır.

Performansı artırmak amacıyla aşağıdaki öneriler değerlendirilebilir:

- Daha derin encoder mimarileri (örneğin ResNet34, EfficientNet)
- Daha fazla görsel augmentasyon

8. Ekstra Deneysel Katkılar

Modelin başarımını artırmak amacıyla bazı ek deneysel çalışmalar yapılmıştır. Eğitim verisine veri artırma (horizontal flip, rotasyon, parlaklık değişimi) uygulanarak modelin genelleme kabiliyeti artırılmıştır. Eğitim sürecine erken durdurma (early stopping) mekanizması eklenmiş, overfitting önlenmiştir. Ayrıca BCE ve Dice loss fonksiyonları birleştirilerek daha dengeli bir öğrenme sağlanmıştır. Eğitim süreci boyunca TensorBoard kullanılarak doğruluk ve kayıplar izlenmiş, her epoch'ta input, tahmin ve gerçek maskeler görsel olarak loglanmıştır. Bu katkılar, hem modelin başarımına hem de proje kalitesine olumlu etki sağlamıştır.

9. Sonuç

Bu çalışmada, U-Net tabanlı bir derin öğrenme modeli ile ISIC2018 cilt lezyonları veri seti üzerinde segmentasyon yapılmıştır.

Eğitim süreci boyunca TensorBoard ile performans izlenmiş, test başarımları ise yüksek bulunmuştur.

Elde edilen sonuçlar literatürle uyumlu olup, model klinik ön tanı sistemleri için potansiyel göstermektedir.

Muhammed Emin Korkunc - All Rights Reserved